

2025 · AI 소프트웨어학과

AI VTuber 자율 방송 시스템

24시간 스스로 방송하는 AI 스트리머 구현
채팅 수집 / LLM 추론 / TTS / 아바타 제어 / 메모리

AI 소프트웨어학과 | 학번 2601110276



Python 3.11 Groq LLM ChromaDB Edge TTS VTube Studio Discord Bot Whisper STT Ollama

OVERVIEW

| 프로젝트 개요

무엇을 만들었나?

사람 없이 24시간 혼자 방송하는 AI 스트리머입니다.

자율 운영

Discord 봇으로 원격 제어만 하면 나머지는 AI가 알아서 진행합니다.

기억하는 AI

시청자 이름과 대화 내용을 벡터 DB에 저장해 기억합니다.

도구 사용

필요하면 스스로 웹 검색과 게임 데이터 조회를 합니다.

전체 동작 흐름

채팅 수집

필터링

메모리 검색

LLM 추론

TTS 합성

아바타 출력

개발 동기

- Eternal Return 게임을 직접 플레이하는 AI 에이전트 프로젝트를 진행 중이었습니다.
- 해당 AI가 방송까지 혼자 진행하면 어떨까 하는 아이디어에서 출발했습니다.
- 단순 챗봇을 넘어 메모리·도구 사용·실시간 음성 합성을 통합한 시스템을 목표로 삼았습니다.

채팅 수집

WebSocket 실시간

LLM 추론

Think + Answer 2단계

메모리

ChromaDB 단기+장기

음성

Whisper STT + Edge TTS

아바타

VTuber Studio API


제어

Discord 봇

ARCHITECTURE

시스템 아키텍처

레이어별 연결 구조



CORE FEATURES

| 핵심 기능 1

메모리 시스템 & LLM 파이프라인

메모리 시스템 — 시청자를 기억하는 방식

단기 메모리

- 최근 대화 5개를 유지합니다
- 대화 흐름이 끊기지 않게 합니다
- ChromaDB 벡터 DB에 저장합니다

장기 메모리 (Wiki)

- 시청자별 정보를 누적 저장합니다
- 이름·관심사·과거 대화를 기록합니다
- 유사도 검색으로 필요한 기억을 불러옵니다

핵심 기술: ChromaDB / 임베딩 벡터 / RAG 패턴 / 코사인 유사도 검색

LLM 파이프라인 — 2단계로 응답을 생성하는 이유

Step 1 · Think

llama-3.3-70b (Groq)

상황을 분석하고
무엇을 말할지 판단
내부적으로만 사용

Step 2 · Tool

검색 · 게임 API

필요하다고 판단되면
외부 정보를 가져옴
판단은 AI가 스스로

Step 3 · Answer

llama-3.1-8b (Groq)

실제 방송에서
발화할 문장 생성
짧고 자연스럽게

핵심 기술: Groq API / Ollama / LLM 체이닝 / 프롬프트 엔지니어링 / 모델 라우팅

CORE FEATURES

핵심 기능 2

음성 I/O / 아바타 제어 / Tool Use

음성 I/O

말하고 듣는 AI

- **STT** 마이크 → Whisper → 텍스트
- **TTS** 텍스트 → Edge TTS → 음성
- **피치** +20Hz 캐릭터 음색 구현
- **속도** +5% 자연스러운 발화

아바타 제어

표정이 바뀌는 Live2D

- **API** VTube Studio WebSocket
- **립싱크** TTS 출력과 동기화
- **감정** 기쁨·놀람·당황 등
- **캐릭터** Niki → Eternal Return

Tool Use

스스로 도구를 사용

- **검색** 웹 검색으로 최신 정보
- **게임** Eternal Return API 조회
- **코드** 코드 분석 및 설명
- **판단** 시가 스스로 필요성 결정

운영 환경

서버	Apple M1 맥미니 8GB — 24시간 방송 송출 전담
Discord	봇으로 원격 제어 // /mode 1 (음성) // /mode 2 (채팅)
환경	macOS / Python 3.11 / conda (vtuber) 가상환경
방송	치지직 플랫폼 / OBS 연동 / 24시간 상시 운영

주요 파일 구조

ai-vtuber/	
├─ main.py	전체 실행 진입점
├─ brain/	agent · llm_config · presenter · tools/
├─ avatar/vtube_bridge.py	VTube Studio WebSocket
├─ chat/reader.py	치지직 채팅 수집
├─ control/	discord_bot.py · filter.py
└─ prompts/	think.txt · answer.txt · snake.txt

TECH STACK

기술 스택

사용한 기술과 역할 정리

역할	기술	설명
채팅 수집	WebSocket	치지직 실시간 채팅 수집
음성 인식	Groq Whisper STT	빠른 실시간 전사
음성 합성	Edge TTS	피치 +20Hz / 속도 +5%
추론 (Think)	Groq llama-3.3-70b	내부 상황 판단 전용
추론 (Answer)	Groq llama-3.1-8b	실제 발화 문장 생성
보조 모델	Ollama gemma4:26b	학교 서버 활용
벡터 DB	ChromaDB	단기 + 장기 메모리
아바타	VTube Studio API	Live2D WebSocket 제어
원격 제어	Discord.py	슬래시 커맨드 / 모드 전환
실행 환경	Python 3.11 / conda	Apple M1 맥미니 8GB

개발하면서 배운 것

- LLM 여러 개를 체이닝하는 방법
- 벡터 DB로 AI에 기억을 주는 방법
- WebSocket 비동기 통신 구조
- 실시간 시스템 설계 (큐, 이벤트)
- M1에서 AI 파이프라인 최적화

어려웠던 점

- M1 8GB에서 메모리 부족 문제
- 실시간 지연 없이 파이프라인 연결
- LLM 응답 품질과 속도 균형
- VTube Studio API 문서 부족
- 24시간 안정적 운영 유지

ROADMAP

향후 계획

앞으로 추가할 기능들

1

Mode 전환

Discord /mode 명령어

음성 ↔ 채팅 렌타임 전환
방송 중 중단 없이 전환 가능하게

2

VLM 연동

이미지 이해 AI 추가

영상 도네이션 분석 리액션
카페 이미지 분석 반응

3

LoRA 파인튜닝

캐릭터 특화 학습

쌍인 대화 데이터로 학습
Niki 말투·성격 강화

4

학습 분리

RTX 5060Ti 메인컬

게임 AI 학습 메인컬 분리
M1은 방송 송출에만 집중

"단순 챗봇을 넘어, 기억하고 생각하고 말하는 AI를 만들었습니다."

프로젝트 최종 요약

플랫폼	치지직 24시간 실시간 방송
AI 모델	Groq llama-3.3-70b (Think) + llama-3.1-8b (Answer) + Ollama gemma4:26b
메모리	ChromaDB — 단기 대화 5개 + 장기 시청자 Wiki
음성	Groq Whisper STT 입력 / Edge TTS 출력 (피치 +20Hz)
아바타	VTube Studio WebSocket API — Live2D 표정·립싱크 실시간 제어
제어	Discord 봇 — 슬래시 커맨드로 원격 운영
서버	Apple M1 맥미니 8GB / Python 3.11 / conda (vtuber)